



**AGH**

**AKADEMIA GÓRNICZO-HUTNICZA  
IM. STANISŁAWA STASZICA  
W KRAKOWIE**

**Metody Obliczeniowe w Nauce i Technice**  
Sprawozdanie z metod rozwiązywania  
układów równań liniowych

Maciej Kmąk  
Informatyka WI AGH, II rok  
14. Czerwca 2025

# 1 Cel Ćwiczenia

Celem ćwiczenia jest przeanalizowanie i porównanie wybranych metod rozwiązywania układów równań liniowych postaci  $Ax = b$  z punktu widzenia:

1. **Złożoności obliczeniowej i zużycia pamięci** różnych algorytmów oraz pomiar rzeczywistych czasów wykonania i wielkości zaalokowanej pamięci.
2. **Stabilności i zbieżności** – analiza współczynnika uwarunkowania  $\kappa(A)$  dla metod bezpośrednich oraz promienia spektralnego  $\rho(G)$  macierzy iteracji w metodzie Jacobiego.
3. **Dokładności numerycznej** – ocena wpływu błędów zaokrągleń (na przykładzie precyzji `float32` i `float64` z biblioteki `NumPy`) oraz współczynnika uwarunkowania macierzy  $\kappa(A)$  na uzyskane rozwiązania (normy  $\|x_{\text{zadany}} - x_{\text{obliczony}}\|_{\infty}$  i  $\|\cdot\|_2$ ).

Badania obejmowały trzy pod-zadania:

**Zadanie 6a** Macierze pełne (źle uwarunkowana macierz hilbertowska oraz macierz symetryczna); rozwiązanie metodą eliminacji Gaussa.

- Macierz hilbertowska:

$$a_{ij} = \begin{cases} 1, & i = j, \\ \frac{1}{i+j-1}, & i \neq j, \end{cases} \quad i, j = 1, 2, \dots, n.$$

- Macierz symetryczna:

$$a_{ij} = \begin{cases} \frac{2i}{j}, & i \geq j, \\ a_{ji}, & i < j, \end{cases} \quad i, j = 1, 2, \dots, n.$$

**Zadanie 6b** Macierz trójdzielna; porównanie eliminacji Gaussa i algorytmu Thomasa.

- Macierz trójdzielna:

$$A^{n \times n} = \begin{cases} 6, & i = j, \\ \frac{1}{i+4}, & j = i+1, \\ \frac{6}{i+4+1}, & j = i-1, \\ 0, & |i-j| > 1. \end{cases}$$

**Zadanie 7** Macierze o strukturze  $a_{ii} = k$ ,  $a_{ij} = 1/(|i-j|+m)$ ; rozwiązanie metodą Jacobiego z dwoma kryteriami stopu oraz wyznaczenie promienia spektralnego macierzy iteracji.

- Macierz z zadania:

$$a_{i,i} = 7, \quad a_{i,j} = \frac{1}{|i-j|+4} \quad (i \neq j, \ i, j = 1, \dots, n).$$

## 2 Dane techniczne

Doświadczenie zostało przeprowadzone na komputerze osobistym o specyfikacji:

- System Operacyjny: Windows 11 Pro
- Procesor: 12th Gen Intel(R) Core(TM) i5-1235U 1.3 GHz
- Język: Python 3.12

## 3 Przebieg doświadczenia

### Zadanie 6a – macierze źle (hilbertowska) i dobrze uwarunkowane ( $2i/j$ )

1. Zakresy wymiarów macierzy  $n$ :

- *Hilbertowska*:  $n = 2, 3, \dots, 100$ .
- *Macierz  $2i/j$* :  $n \in \{2, 3, \dots, 100\} \cup \{110, 120, \dots, 500\}$ .

2. Dla każdego  $(n, \text{dtype})$ :

- Generacja wektora wzorcowego  $\mathbf{x}_{\text{true}} \in \{\pm 1\}^n$ .
- Budowa macierzy  $A$  i obliczenie  $\mathbf{b} = A\mathbf{x}_{\text{true}}$ .
- Wyznaczenie współczynnika uwarunkowania

$$\kappa(A) = \|A\|_{\infty} \|A^{-1}\|_{\infty}.$$

- Rozwiązanie  $A\mathbf{x} = \mathbf{b}$  metodą eliminacji Gaussa.
- Obliczenie błędów:

$$e_{\max} = \|\mathbf{x}_{\text{true}} - \mathbf{x}_{\text{calc}}\|_{\infty}, \quad e_{\text{euk}} = \|\mathbf{x}_{\text{true}} - \mathbf{x}_{\text{calc}}\|_2.$$

### Zadanie 6b – macierz trójdzielna

1. Zakresy wymiarów:  $n \in \{2, \dots, 100\} \cup \{110, 120, \dots, 1000\}$ .

2. Dla każdego  $(n, \text{dtype})$ :

- Generacja wektorów macierzy oraz losowego  $\mathbf{x}_{\text{true}} \in \{\pm 1\}^n$ .
- Obliczenie  $\mathbf{b} = A_{\text{tri}} \mathbf{x}_{\text{true}}$ .
- Rozwiązanie układu dwiema metodami:
  - *Algorytm Thomasa* (złożoność czasowa  $O(n)$ , pamięciowa  $O(n)$ ),
  - *Eliminacja Gaussa* (złożoność czasowa  $O(n^3)$ , pamięciowa  $O(n^2)$ ).
- Pomiar czasu wykonania i zużycia pamięci (moduł `tracemalloc`).
- Obliczenie błędów  $e_{\max}$ ,  $e_{\text{euk}}$ .

## Zadanie 7 – metoda Jacobiego

### 1. Badanie progu zbieżności:

- Konstruowano macierz  $A$  dla  $n = 1, \dots, 1000$ .
- Dla każdego  $n$  obliczano promień spektralny macierzy iteracji Jacobiego.
- Zidentyfikowano pierwszy  $n_0$ , dla którego  $\rho(G) \geq 1$ .

### 2. Zawężenie badania do $n \in \{3, 5, 10, 20, 30, 40, 50, 100, 200, 300, 400, 500\}$ .

### 3. Schemat pomiarów:

- Kryteria stopu:

$$\|x^{(k+1)} - x^{(k)}\|_\infty < \varepsilon \quad \text{lub} \quad \|Ax^{(k)} - b\|_\infty < \varepsilon,$$

dla  $\varepsilon \in \{10^{-2}, 10^{-3}, 10^{-5}, 10^{-7}, 10^{-9}, 10^{-12}, 10^{-15}\}$ .

- Trzy wektory startowe: zerowy, losowy z  $\{\pm 100\}$  i „pośredni” z  $\{\pm 30, \pm 40, \pm 50, \pm 60\}$ .

### 4. Dla każdej kombinacji $(n, \varepsilon, \text{start})$ :

- Mierzono liczbę iteracji do zbieżności i średni czas jednej iteracji.
- Obliczano błędy końcowe  $e_{\max}$ ,  $e_{\text{euk}}$ .

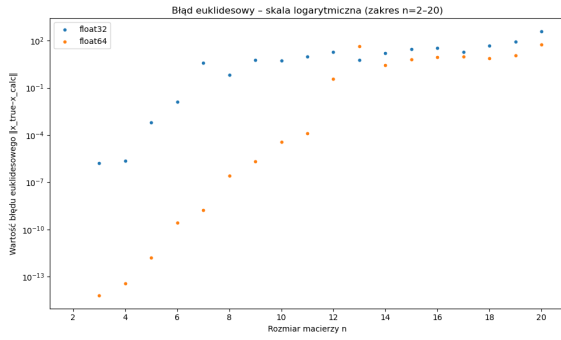
## 4 Wyniki Doświadczenia

### Wyniki doświadczenia 6a cz.1 – macierz źle uwarunkowana

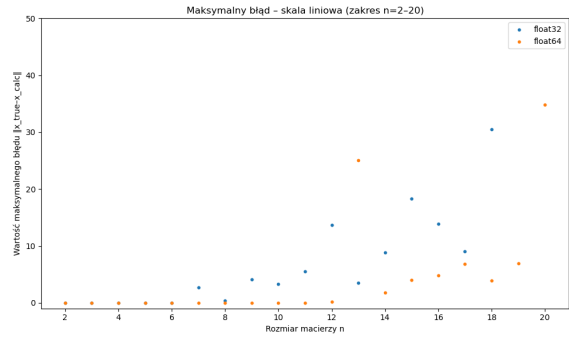
W tabeli 1 oraz na rysunkach 1a, 1b i 2 przedstawiono zebrane dla zakresu  $n = 2$ –20 wartości błędu maksymalnego i euklidesowego oraz współczynnika uwarunkowania macierzy dla precyzji float32 i float64.

**Tabela 1:** Zadanie 6a cz.1: wyniki eksperymentu dla  $n \in \{2, \dots, 20\}$  (float32 vs. float64)

$n$	float32			float64		
	$e_{\max}$	$e_{\text{euk}}$	$\kappa$	$e_{\max}$	$e_{\text{euk}}$	$\kappa$
2	0.000e+00	0.000e+00	8.000e+00	0.000e+00	0.000e+00	8.000e+00
3	1.311e-06	1.660e-06	2.400e+02	5.107e-15	6.489e-15	2.400e+02
4	1.907e-06	2.322e-06	1.530e+04	2.975e-14	3.767e-14	1.530e+04
5	4.644e-04	6.392e-04	7.435e+05	1.125e-12	1.559e-12	7.431e+05
6	8.652e-03	1.298e-02	3.266e+07	1.807e-10	2.678e-10	3.216e+07
7	2.677e+00	3.849e+00	1.950e+09	1.162e-09	1.670e-09	1.417e+09
8	4.133e-01	6.608e-01	1.250e+10	1.795e-07	2.677e-07	5.566e+10
9	4.133e+00	5.855e+00	1.487e+11	1.318e-06	2.150e-06	2.019e+12
10	3.290e+00	5.326e+00	1.956e+10	2.235e-05	3.545e-05	8.025e+13
11	5.538e+00	9.358e+00	9.681e+09	8.048e-05	1.328e-04	3.014e+15
12	1.365e+01	1.939e+01	1.139e+10	2.253e-01	3.769e-01	1.090e+17
13	3.458e+00	6.108e+00	4.776e+10	2.501e+01	4.246e+01	3.190e+18
14	8.869e+00	1.603e+01	2.123e+10	1.747e+00	2.809e+00	5.476e+18
15	1.831e+01	2.950e+01	2.395e+10	4.037e+00	6.354e+00	6.797e+18
16	1.388e+01	3.289e+01	6.037e+10	4.837e+00	8.773e+00	7.414e+18
17	9.063e+00	1.842e+01	1.511e+11	6.808e+00	9.786e+00	9.695e+18
18	3.052e+01	4.764e+01	7.394e+10	3.891e+00	7.472e+00	5.371e+19
19	5.168e+01	8.536e+01	7.890e+10	6.956e+00	1.169e+01	3.423e+19
20	2.125e+02	3.766e+02	8.415e+10	3.479e+01	5.495e+01	5.351e+20



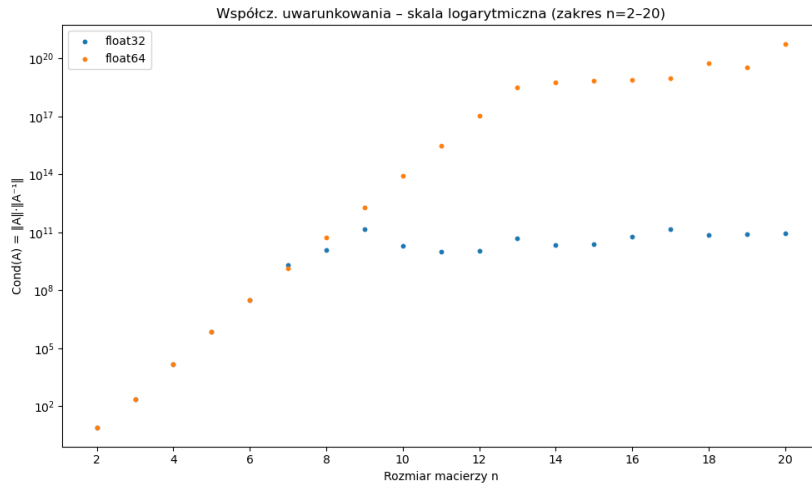
(a) Norma euklidesowa - skala logarytmiczna



(b) Norma maksimum - skala liniowa

**Rysunek 1:** Wykresy błędów: euklidesowego i maksimum  $\|x_{\text{true}} - x_{\text{calc}}\|$  dla precyzji float32 i float64

Macierz  $A$  w zadaniu 1 z ćwiczenia 6a to zmodyfikowana macierz Hilberta, w której pierwszy wiersz składa się z samych jedynek ( $a_{1j} = 1$ ), a pozostałe elementy odpowiadają klasycznej definicji macierzy Hilberta. Taka konstrukcja prowadzi do silnie złego uwarunkowania, co możemy zauważyć także na rys. 2.

**Rysunek 2:** Współczynnik uwarunkowania  $\kappa(A)$  (skala logarytmiczna)

**Uwarunkowanie i rola  $\kappa(A)$ .** Na rysunku 2 możemy zauważyć, że wartość współczynnika  $\kappa(A)$  rośnie bardzo szybko z  $n$ , osiągając rzędy  $10^{10}$  dla float32 oraz  $10^{20}$  dla float64. Skorelowane jest to z gwałtownym wzrostem błędu maksimum: dla precyzji float32 błąd zaczyna istotnie rosnać już od  $n \approx 7$ , natomiast dla float64 dopiero od  $n \approx 13$  (por. Tabela 1, kolumna  $e_{\max}$ ). Możemy więc wnioskować, że  $\kappa(A)$  stanowi wiarygodny wskaźnik prognozowania utraty dokładności obliczeń.

**Wpływ precyzji.** Zastosowanie float64 przesuwaa próg istotnego wzrostu błędów w porównaniu do float32; niemniej, w skrajnie źle uwarunkowanych przypadkach narastanie błędów staje się zauważalne stosunkowo szybko (w badanym układzie przy  $n \approx 13$ ) pomimo użycia podwójnej precyzji.


## Wyniki doświadczenia 6a cz.2 – macierz dobrze uwarunkowana

W tabeli 2 oraz na rysunkach 3a i 3b przedstawiono wyniki dla zakresu

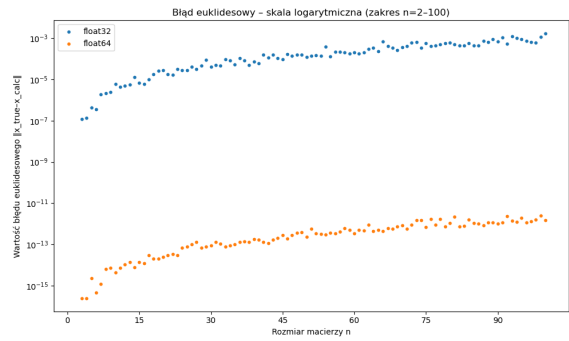
$$n \in \{2, 3, \dots, 20, 25, 30, 40, 50, 75, 100, 150, 200\}$$

**Tabela 2:** Zadanie 6a cz.2: wyniki eksperymentu dla  $n \in \{2, 3, 4, 5, 20, 25, 30, 40, 50, 75, 100, 150, 200\}$  (float32 vs. float64)

$n$	float32			float64		
	$\epsilon_{\max}$	$\epsilon_{\text{euk}}$	$\kappa$	$\epsilon_{\max}$	$\epsilon_{\text{euk}}$	$\kappa$
2	0.000e+00	0.000e+00	3.000e+00	0.000e+00	0.000e+00	3.000e+00
3	1.192e-07	1.192e-07	8.667e+00	2.220e-16	2.483e-16	8.667e+00
4	1.192e-07	1.333e-07	1.650e+01	2.220e-16	2.483e-16	1.650e+01
5	2.980e-07	4.172e-07	2.680e+01	1.554e-15	2.254e-15	2.680e+01
20	1.669e-05	2.821e-05	4.725e+02	1.332e-14	2.423e-14	4.725e+02
25	1.359e-05	2.715e-05	7.424e+02	4.796e-14	7.926e-14	7.424e+02
30	2.128e-05	3.960e-05	1.073e+03	4.996e-14	9.060e-14	1.073e+03
40	2.551e-05	5.840e-05	1.916e+03	7.017e-14	1.665e-13	1.916e+03
50	5.406e-05	1.249e-04	3.002e+03	1.280e-13	2.335e-13	3.002e+03
75	1.726e-04	5.749e-04	6.778e+03	2.736e-13	6.868e-13	6.778e+03
100	5.060e-04	1.644e-03	1.207e+04	4.929e-13	1.527e-12	1.207e+04
150	7.410e-04	2.420e-03	2.720e+04	1.751e-12	5.864e-12	2.720e+04
200	1.211e-03	4.152e-03	4.841e+04	1.390e-12	6.411e-12	4.841e+04



(a) Norma maksimum — skala logarytmiczna



(b) Norma euklidesowa — skala logarytmiczna

**Rysunek 3:** Błędy obliczeń  $\|x_{\text{true}} - x_{\text{calc}}\|$  dla float32 i float64

**Błędy numeryczne.** Na logarytmicznych wykresach normy maksimum i euklidesowej widać stabilny przebieg błędów: krzywe dla float32 są przesunięte o stałą wartość w górę (rzędy wielkości wyższe niż dla float64), niemniej nie pojawiają się nagłe skoki ani gwałtowne odchylenia.

**Uwarunkowanie i rola  $\kappa(A)$ .** Współczynnik  $\kappa(A)$  rośnie stopniowo i bez wyraźnych skoków, co potwierdza dobre uwarunkowanie macierzy – zgodnie z przewidywaniami nie obserwuje się istotnej utraty dokładności w rozwiązywaniu układów. Ponadto, w Tabeli 2 widać, że wartości  $\kappa(A)$  dla precyzji float32 i float64 są identyczne.

## Wyniki doświadczenia 6b – algorytm Thomasa vs. eliminacja Gaussa

Poniżej zestawiono wybrane tabele z wynikami obliczeń dla układów o rozmiarach

$$n \in \{2, 3, \dots, 10, 20, 50, 100, 150, 200, 300, 400, 500, 750, 1000\},$$


porównujące algorytm Thomasa i pełną eliminację Gaussa.

**Tabela 3:** Wyniki eksperymentu – algorytm Thomasa


$n$	float32				float64			
	$e_{\max}$	$e_{\text{euk}}$	$t$ [s]	Pamięć [B]	$e_{\max}$	$e_{\text{euk}}$	$t$ [s]	Pamięć [B]
2	0.000e+00	0.000e+00	7.129e-04	9.500e+02	0.000e+00	0.000e+00	4.980e-05	9.600e+02
3	5.960e-08	5.960e-08	6.840e-05	9.120e+02	1.110e-16	1.110e-16	9.160e-05	9.840e+02
4	1.192e-07	1.192e-07	9.850e-05	9.400e+02	1.110e-16	1.110e-16	7.970e-05	1.040e+03
5	1.192e-07	1.333e-07	9.850e-05	9.680e+02	2.220e-16	2.220e-16	9.990e-05	1.096e+03
6	1.192e-07	1.192e-07	1.182e-04	9.960e+02	2.220e-16	3.331e-16	1.187e-04	1.152e+03
7	1.192e-07	1.788e-07	1.486e-04	1.024e+03	2.220e-16	2.719e-16	1.489e-04	1.208e+03
8	1.192e-07	1.788e-07	1.608e-04	1.052e+03	1.110e-16	1.923e-16	1.582e-04	1.264e+03
9	1.192e-07	2.230e-07	2.812e-04	1.080e+03	2.220e-16	3.846e-16	1.920e-04	1.320e+03
10	5.960e-08	5.960e-08	2.036e-04	1.108e+03	2.220e-16	2.937e-16	3.152e-04	1.376e+03
20	1.192e-07	2.308e-07	3.916e-04	1.388e+03	2.220e-16	3.331e-16	3.910e-04	1.936e+03
50	1.788e-07	3.909e-07	1.165e-03	2.228e+03	2.220e-16	7.022e-16	1.235e-03	3.616e+03
100	1.192e-07	6.166e-07	1.894e-03	3.628e+03	2.220e-16	1.047e-15	2.164e-03	6.416e+03
200	1.192e-07	7.633e-07	4.699e-03	6.428e+03	3.331e-16	1.506e-15	5.264e-03	1.202e+04
300	1.788e-07	9.629e-07	7.446e-03	9.308e+03	3.331e-16	1.720e-15	1.083e-02	1.770e+04
400	1.788e-07	1.132e-06	9.170e-03	1.211e+04	2.220e-16	1.769e-15	1.462e-02	2.330e+04
500	1.788e-07	1.176e-06	1.541e-02	1.491e+04	3.331e-16	2.161e-15	1.217e-02	2.890e+04
750	1.192e-07	1.507e-06	2.395e-02	2.191e+04	3.331e-16	2.753e-15	2.380e-02	4.290e+04
1000	1.788e-07	1.761e-06	5.323e-02	2.891e+04	3.331e-16	3.329e-15	3.504e-02	5.690e+04

**Tabela 4:** Wyniki eksperymentu – eliminacja Gaussa


$n$	float32				float64			
	$e_{\max}$	$e_{\text{euk}}$	$t$ [s]	Pamięć [B]	$e_{\max}$	$e_{\text{euk}}$	$t$ [s]	Pamięć [B]
2	0.000e+00	0.000e+00	5.003e-04	1.365e+03	0.000e+00	0.000e+00	1.368e-04	1.384e+03
3	5.960e-08	5.960e-08	2.748e-04	1.376e+03	1.110e-16	1.110e-16	1.781e-04	1.488e+03
4	1.192e-07	1.192e-07	2.613e-04	1.444e+03	1.110e-16	1.110e-16	2.167e-04	1.624e+03
5	1.192e-07	1.333e-07	3.871e-04	1.528e+03	2.220e-16	2.220e-16	3.023e-04	1.792e+03
6	1.192e-07	1.192e-07	4.195e-04	1.628e+03	2.220e-16	3.331e-16	3.638e-04	1.992e+03
7	1.192e-07	1.788e-07	5.984e-04	1.744e+03	2.220e-16	2.719e-16	5.345e-04	2.224e+03
8	1.192e-07	1.788e-07	7.069e-04	1.876e+03	1.110e-16	1.923e-16	9.618e-04	2.881e+03
9	1.192e-07	2.230e-07	1.080e-03	2.024e+03	2.220e-16	3.846e-16	6.944e-04	2.784e+03
10	5.960e-08	5.960e-08	9.397e-04	2.188e+03	2.220e-16	2.937e-16	8.721e-04	3.184e+03
20	1.192e-07	2.308e-07	2.707e-03	5.584e+03	2.220e-16	3.331e-16	2.573e-03	1.054e+04
50	1.788e-07	3.909e-07	1.554e-02	3.102e+04	2.220e-16	7.022e-16	1.490e-02	6.142e+04
100	1.192e-07	6.166e-07	5.359e-02	1.214e+05	2.220e-16	1.047e-15	5.651e-02	2.422e+05
200	1.192e-07	7.633e-07	2.736e-01	4.822e+05	3.331e-16	1.506e-15	4.543e-01	9.638e+05
300	1.788e-07	9.629e-07	8.278e-01	1.083e+06	3.331e-16	1.720e-15	8.710e-01	2.165e+06
400	1.788e-07	1.132e-06	1.678e+00	1.924e+06	2.220e-16	1.769e-15	1.711e+00	3.847e+06
500	1.788e-07	1.176e-06	1.821e+00	3.005e+06	3.331e-16	2.161e-15	1.797e+00	6.009e+06
750	1.192e-07	1.507e-06	4.008e+00	6.757e+06	3.331e-16	2.753e-15	3.948e+00	1.351e+07
1000	1.788e-07	1.761e-06	1.166e+01	1.201e+07	3.331e-16	3.329e-15	1.143e+01	2.402e+07




**Rysunek 4:** Porównanie czasu obliczeń [s] (skala liniowa) dla metod Thomasa i Gaussa.



(a) Alorytm Thomasa



(b) Eliminacja Gaussa

**Rysunek 5:** Porównanie zużycia pamięci (w bajtach) w zależności od  $n$ .**Rysunek 6:** Porównanie błędu euklidesowego  $e_{\text{euk}} = \|x_{\text{true}} - x_{\text{calc}}\|_2$  w skali logarytmicznej.

**Czas obliczeń:** Z porównania (Rys. 4) wynika, że czas rozwiązania układu trójdziagonalnego algorytmem Thomasa rośnie liniowo wraz ze wzrostem rozmiaru  $n$ , co potwierdza jego złożoność  $\mathcal{O}(n)$ . Natomiast pełna eliminacja Gaussa wykazuje typowy dla siebie przebieg sześcienny  $\mathcal{O}(n^3)$ , przez co dla większych  $n$  staje się znacznie wolniejsza.

**Zużycie pamięci:** Rysunek 5a pokazuje, że algorytm Thomasa wykorzystuje pamięć proporcjonalnie do  $n$  (trzy wektory długości  $n$ ), natomiast eliminacja Gaussa (rys. 5b) – ze względu na pełne przechowywanie macierzy  $n \times n$  – wymaga przestrzeni kwadratowej  $\mathcal{O}(n^2)$ . Dodatkowo wyższa precyzja (float64) skutkuje dwukrotnym zwiększeniem zużycia pamięci w obu metodach.

**Dokładność rozwiązań:** Jak ilustruje wykres błędu euklidesowego (Rys.6), obie metody osiągają porównywalną dokładność: wartości  $e_{\text{max}}$  i  $e_{\text{euk}}$  nie różnią się pomiędzy algorytmem Thomasa a eliminacją Gaussa. Jedynym czynnikiem wpływającym na wielkość błędów jest zastosowana precyzja zmiennoprzecinkowa (float32 vs. float64) a nie sam algorytm.



## Wyniki doświadczenia 7 – metoda Jacobiego

W pierwszym etapie badania obliczono promień spektralny  $\rho(G)$  dla wybranych rozmiarów układu  $n$ . Wyniki przedstawiono w Tabeli 5. Z Tabeli 5b widać, że promień spektralny po raz pierwszy przekracza 1 przy  $n = 362$ . Na Rysunku 7 zaprezentowano przebieg  $\rho(G)$  w całym badanym zakresie oraz powiększenie fragmentu wokół  $n \approx 362$ . Badanie promienia spektralnego macierzy iteracyjnej  $G$  wykazało, że  $\rho(G) < 1$  dla  $n \leq 300$ , a  $\rho(G) > 1$  już od  $n = 362$ . W dalszych testach skupiono się więc na „zbieżnych” układach  $n \leq 300$  oraz „niezbieżnych”  $n \geq 400$ , rozwiązując je metodą Jacobiego w precyzji `float64`.

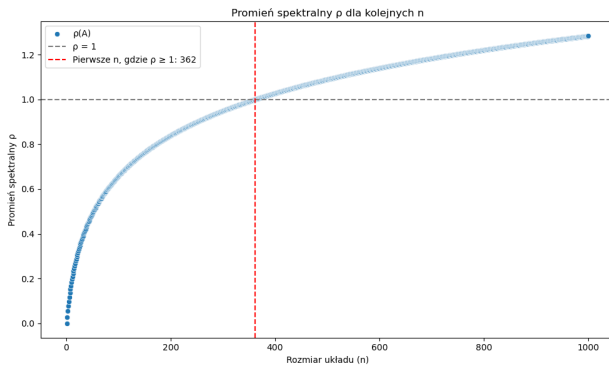
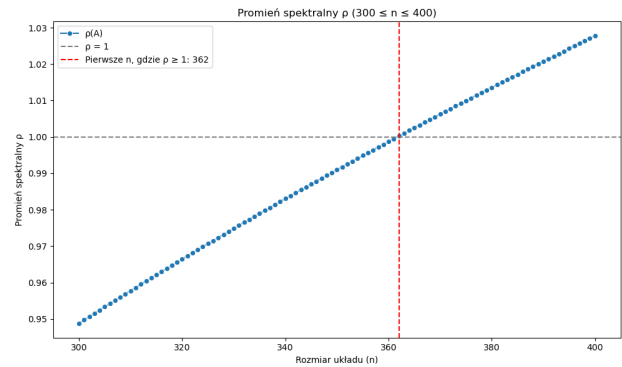
(a)  $n \in \{100, 200, 300, 400\}$ 

$n$	$\rho(G)$
100	0.6584
200	0.8392
300	0.9488
400	1.0277

(b)  $\rho(G)$  dla  $360 \leq n \leq 363$ 

$n$	$\rho(G)$
360	0.99872
361	0.99948
362	1.00024
363	1.00100


**Tabela 5:** Promień spektralny  $\rho(G)$ : porównanie wybranych wartości

(a) Zakres  $1 \leq n \leq 1000$ (b) Fragment  $300 \leq n \leq 400$ 



**Rysunek 7:** Promień spektralny  $\rho(G)$  w zależności od  $n$ .

Jako kryteria stopu przyjęto normę przyrostu  $\|x^{(k+1)} - x^{(k)}\|_\infty < \varepsilon$  i residualną  $\|Ax^{(k)} - b\|_\infty < \varepsilon$ , oraz trzy typy wektora początkowego: zerowy, losowy z  $\{\pm 100\}$  i „pośredni” z  $\{\pm 30, \pm 40, \pm 50, \pm 60\}$ .

### Kryterium przyrostowe – liczba iteracji



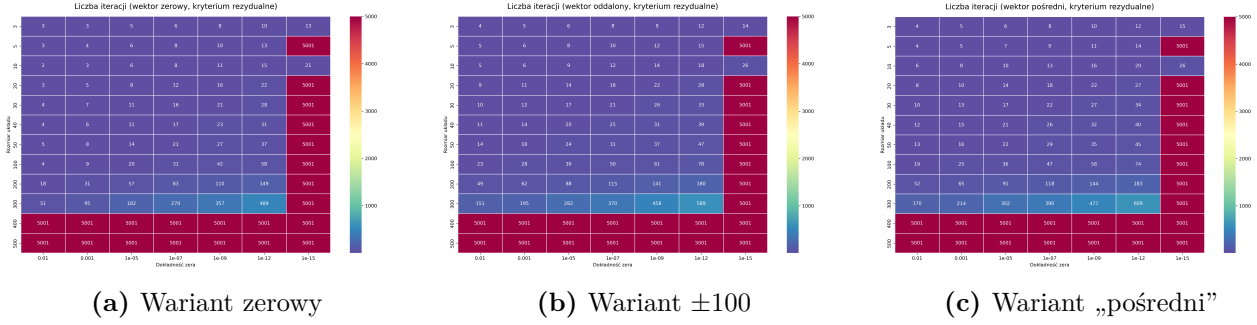
(a) Wariant zerowy

(b) Wariant  $\pm 100$ 

(c) Wariant „pośredni”

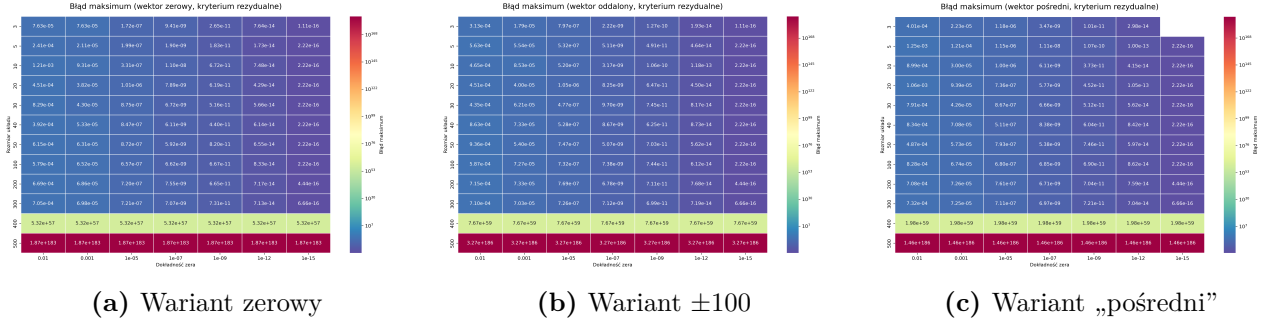
**Rysunek 8:** Liczba iteracji do spełnienia kryterium przyrostowego  $\|x^{(k+1)} - x^{(k)}\|_\infty < \varepsilon$ .

## Kryterium residualne – liczba iteracji



**Rysunek 9:** Liczba iteracji do spełnienia kryterium residualnego  $\|Ax^{(k)} - b\|_\infty < \varepsilon$ .

Warto zauważyć, że dla kryterium residualnego i tolerancji  $\varepsilon = 10^{-15}$  w większości przypadków (por. Rys. 9a, 9b, 9c) iteracje dochodziły do ustawionego limitu, mimo to końcowe wartości błędu maksymalnego  $e_{\max}$  były zgodne z ograniczeniami arytmetyki liczb zmiennoprzecinkowych (zob. Rysunek 10).

Kryterium residualne – błąd maksymalny  $e_{\max}$ 

**Rysunek 10:** Błąd maksymalny  $e_{\max} = \|x_{\text{true}} - x^{(N)}\|_\infty$  przy kryterium residualnym.

Ostateczne wnioski płynące z analizy promienia spektralnego oraz przebiegu iteracji przedstawiają się następująco:

- Dla  $n \leq 300$  ( $\rho(G) < 1$ ) metoda Jacobiego konverguje, zaś gdy  $\rho(G) > 1$  (od  $n = 362$ ), brak jest zbieżności w zadanym limicie kroków.
- Kryterium przyrostowe generuje zwykle mniejszą liczbę iteracji niż residualne, ale prowadzi do wyższych błędów końcowych.
- Kryterium residualne zapewnia lepszą kontrolę dokładności kosztem większej liczby iteracji i dłuższego czasu pojedynczej iteracji.
- Wariant zerowy wektora startowego daje najszybszą zbieżność i najniższe błędy, natomiast wektor „oddalony” ( $\pm 100$ ) wymaga najwięcej iteracji, zwłaszcza przy mniejszych tolerancjach.

## 5 Podsumowanie Zagadnienia

Badania obejmowały trzy problemy: (6a) układy o pełnych macierzach dobrze i źle uwarunkowanych, (6b) układy trójdzielne, (7) układy rozwiązywane metodą Jacobiego. Poniżej syntetyzujemy najważniejsze wnioski.

### Uwarunkowanie a metody bezpośrednie (Zadanie 6a)

- **Macierz hilbertowska (złe uwarunkowanie).** Współczynnik uwarunkowania osiągał rzędy  $10^{10} - 10^{20}$ ; odpowiadało to lawinowemu wzrostowi błędów  $e_{\max}$  od  $n \approx 7$  (float32) i  $n \approx 13$  (float64). Podwójna precyzja tylko *opóźniła* katastrofę numeryczną – nie usuwała jej przy skrajnie źle uwarunkowanych macierzach.
- **Macierz  $2i/j$  (dobre uwarunkowanie).**  $\kappa(A)$  rosło wolno (maks.  $\approx 10^5$ ), a profil błędów pozostawał gładki; różnice między float32 i float64 sprowadzały się do stałego przesunięcia o kilka rzędów wielkości, zgodnego z oczekiwaniami dla różnych precyzji liczb zmiennoprzecinkowych.

Współczynnik uwarunkowania  $\kappa(A)$  jest wiarygodnym predyktorem jakości rozwiązania dla metod bezpośrednich: nagły skok  $\kappa$  zwiastuje równie nagły wzrost błędów, zaś wysoka precyzja nie zastąpi dobrego uwarunkowania macierzy.

### Macierze trójdzielne – Thomas vs. Gauss (Zadanie 6b)

- **Złożoność.** Algorytm Thomasa potwierdził złożoność czasową i pamięciową  $O(n)$ ; pełna eliminacja Gaussa – odpowiednio  $O(n^3)$  i  $O(n^2)$ . Przy  $n = 1000$  Thomas był ok.  $200 \times$  szybszy i  $400 \times$  oszczędniejszy pamięciowo.
- **Dokładność.** Obie metody dawały identyczne wartości  $e_{\max}$  oraz  $e_{\text{euk}}$ . O błędzie decydowała wyłącznie precyzja (float32/float64), a nie dobór algorytmu.

W przypadku układów trójdzielnych algorytm Thomasa pozwala uzyskać porównywalną dokładność rozwiązań przy znacznie niższych kosztach obliczeniowych i pamięciowych niż pełna eliminacja Gaussa.

### Metoda Jacobiego – granice zbieżności (Zadanie 7)

#### Promień spektralny i zbieżność

Promień spektralny  $\rho(G)$  stanowi dobry wskaźnik zbieżności metod iteracyjnych – układy konvergują jedynie wtedy, gdy  $\rho(G) < 1$ .

#### Kryteria stopu i wektory startowe

- **Kryterium przyrostowe** wymagało mniej iteracji, lecz kończyło z większymi błędami.
- **Kryterium residualne** zapewniało niższy błąd kosztem większej liczby iteracji i dłuższego czasu na iterację.
- Wektor startowy *zerowy* zbiegał najszybciej i z najmniejszą liczbą iteracji, podczas gdy wektor  $\pm 100$  wymagał największej liczby kroków, szczególnie przy mniejszych tolerancjach  $\varepsilon \leq 10^{-9}$ .

#### Ograniczenia arytmetyki zmiennoprzecinkowej

Przy kryterium residualnym i tolerancji  $\varepsilon = 10^{-15}$  iteracje w większości przypadków dochodziły do ustawionego limitu (por. Rys. 9 i 10), mimo to uzyskane wartości błędów maksymalnego  $e_{\max}$  pozostawały w granicach około  $10^{-14}$ , co uwiadamia wpływ ograniczonej precyzji zmiennoprzecinkowej.